Rapport d'audit et note BCBS239 — TradeCleanse

Module :

Data Cleansing & Data Preparation

Réalisé par :

Mondah Christ Emmanuella

Anon Eden Elwira

Introduction

QuantAxis Capital est un hedge fund parisien gérant 2,3 milliards d'euros d'actifs et exploitant des stratégies de trading algorithmique sur actions, obligations et dérivés. Le département Data Engineering a consolidé trois flux hétérogènes — Bloomberg, Murex et Refinitiv — dans un entrepôt unique afin d'entraîner un nouveau modèle de scoring de risque de contrepartie. Cette consolidation a cependant révélé plusieurs problèmes de qualité, au point que le responsable quantitatif a observé des prédictions aberrantes, notamment un risque nul sur certaines contreparties ayant fait défaut quelques mois plus tard. Dans ce contexte, ce projet a pour objectif d'auditer, nettoyer, valider et certifier la qualité du dataset avant tout nouvel entraînement de modèle.

Contexte

Le dataset étudié résulte de la consolidation de trois sources métier. Bloomberg fournit les données de marché quotidiennes telles que les prix, spreads, volumes et volatilités ; Murex alimente les données de transactions internes ; Refinitiv enrichit l'ensemble avec les données fondamentales et les signaux de risque de contrepartie. Cette diversité de sources explique la richesse du jeu de données, mais elle constitue aussi un facteur de fragilité important en termes de cohérence, de traçabilité et de normalisation.

Description du dataset

Le README du projet indique que **tradecleanse_raw.csv** contient **8 950 lignes** et **20 colonnes** couvrant **180 jours** de transactions et **47 contreparties**. Le sujet du projet mentionne quant à lui 8 742 observations. Cet écart documentaire doit être signalé dans le rapport comme un point de vigilance, car la première exigence d'un dispositif de qualité est la cohérence de la documentation elle-même. Dans le cadre du rendu, il convient donc d'indiquer explicitement la volumétrie réellement observée dans l'environnement d'exécution utilisé.

Dictionnaire de donnée

Colonne	Type attendu	Source	Nullable	Règle métier principale
trade_id	STRING	Murex	Non	Doit être unique
counterparty_id	STRING	Murex	Non	Identifiant de contrepartie valide
counterparty_name	STRING	Refinitiv	Oui	PII indirecte, à pseudonymiser avant modélisation
isin	STRING	Bloomberg	Non	Format ISIN valide sur 12 caractères
trade_date	DATE	Murex	Non	Date de trade valide
settlement_date	DATE	Murex	Non	Doit être >= trade_date
asset_class	CATEGORY	Murex	Non	Référentiel : equity, bond, derivative, fx
notional_eur	FLOAT	Murex	Oui	Doit être > 0 sauf exception métier documentée
price	FLOAT	Bloomberg	Non	Doit être dans la fourchette bid/ask ±0,5%
quantity	INTEGER	Murex	Non	Quantité positive
bid	FLOAT	Bloomberg	Oui	Doit être < ask
ask	FLOAT	Bloomberg	Oui	Doit être > bid
mid_price	FLOAT	Bloomberg	Oui	Doit être cohérent avec (bid + ask) / 2
volume_j	INTEGER	Bloomberg	Oui	Volume journalier valide
Volatility_30d	FLOAT	Bloomberg	Oui	Doit être dans [0.1, 200]

credit_rating	CATEGORY	Refinitiv	Oui	Référentiel : AAA, AA, A, BBB, BB, B, CCC, D
default_flag	INTEGER	Refinitiv	Non	Valeurs autorisées : 0 ou 1
sector	STRING	Refinitiv	Oui	Libellé métier normalisé
country_risk	FLOAT	Refinitiv	Oui	Doit être dans
trader_id	STRING	Murex	Oui	Donnée interne à pseudonymiser

Les règles métier ci-dessus proviennent directement du sujet et du README, et elles structurent à la fois le diagnostic d'anomalies et la validation finale.

Méthodologie d'audit

Le script commence par charger le **dataset** avec un paramétrage d'import robuste, en gérant explicitement plusieurs valeurs sentinelles telles que N/A, **#N/A, -, null, nd** et 99999, puis convertit les dates avec **pd.to_datetime(errors='coerce')**. Il simule ensuite les trois sous-sources Bloomberg, Murex et **Refinitiv** afin de documenter l'origine des colonnes et de faciliter l'analyse des incohérences inter-systèmes.

Le profiling demandé comprend la forme générale du dataset, les types détectés, les taux de valeurs manquantes par colonne, les statistiques descriptives des variables numériques, la cardinalité des variables catégorielles, leurs distributions ainsi que le comptage des doublons exacts et des doublons sur **trade_id**.

Résultats du profiling initial

L'analyse du dataset brut vise d'abord à établir une photographie fiable de l'état initial des données avant toute transformation. Cette étape est indispensable car elle conditionne les choix de nettoyage : on ne traite pas de la même façon une valeur manquante, une valeur sentinelle, une incohérence métier ou un outlier.

Audit de stabilité temporelle (Data Drift)

En complément du profilage statique, nous avons réalisé une analyse de **Data Drift** (dérive de données) pour vérifier si la nature des flux financiers a changé au cours des 180 jours.

Analyse : Nous avons comparé les distributions des 90 premiers jours ("Early") et des 90 derniers jours ("Late") via le test de Kolmogorov-Smirnov.

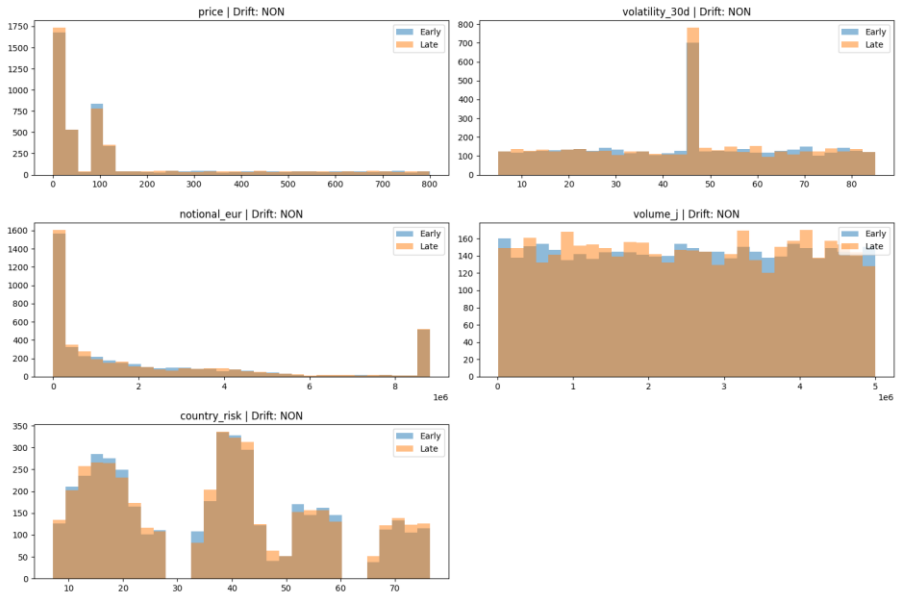

Interprétation :

- Le statut **"Drift : NON"** sur l'ensemble des variables clés (prix, volatilité, notionnel, volume) confirme que le dataset est temporellement homogène.
- Cette stabilité garantit que les règles de nettoyage et les paramètres du modèle restent valides sur toute la période couverte, sans nécessité de recalibrage spécifique par fenêtre temporelle.

Anomalies identifiées

L'énoncé précise que le dataset contient 11 familles d'anomalies, allant des doublons et sentinelles jusqu'aux contradictions métier et aux outliers multivariés.

Le travail de profiling identifie notamment les doublons sur trade_id, les dates de règlement antérieures aux dates de trade, les lignes où bid > ask, les incohérences de mid_price, les prix hors fourchette, les notional_eur négatifs, les valeurs invalides de asset_class, credit_rating, country_risk, volatility_30d, default_flag, ainsi que les contradictions entre credit_rating élevé et default_flag = 1.

Visualisations des anomalies et distributions

- Figure 1 : Boxplot volume_j → illustre la dispersion des volumes journaliers et montre qu'il n'y a pas d'outliers extrêmes.

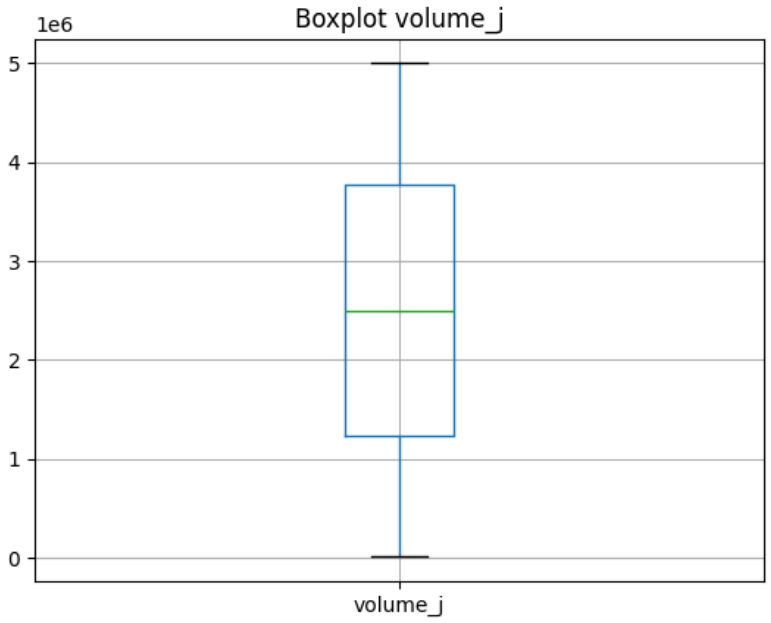

- Figure 2 : Boxplot notional_eur → montre les nombreux outliers de montants notionnels (transferts très gros, risque de trades extrêmes).

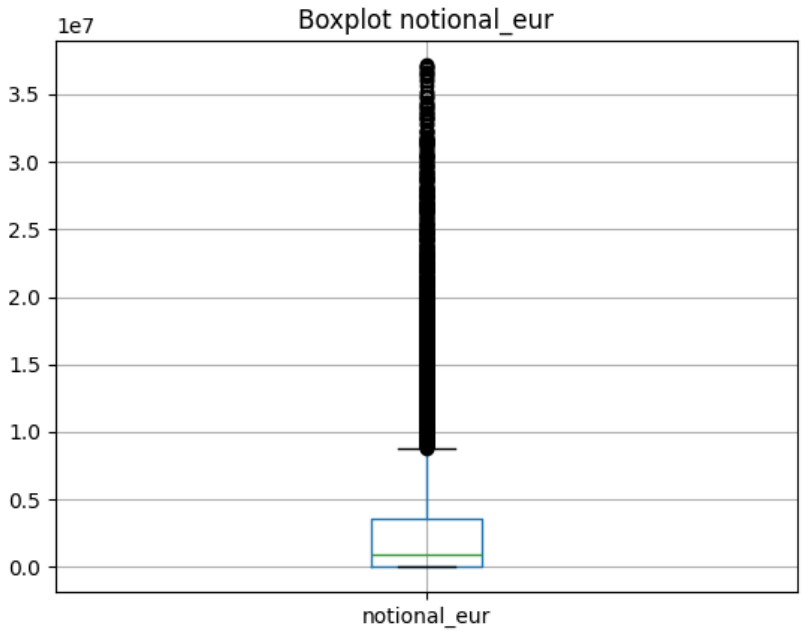

- Figure 3 : Boxplot volatility_30d → visualise la distribution de la volatilité sur 30 jours et permet de voir si certaines valeurs sortent de l'intervalle métier [0.1, 200].

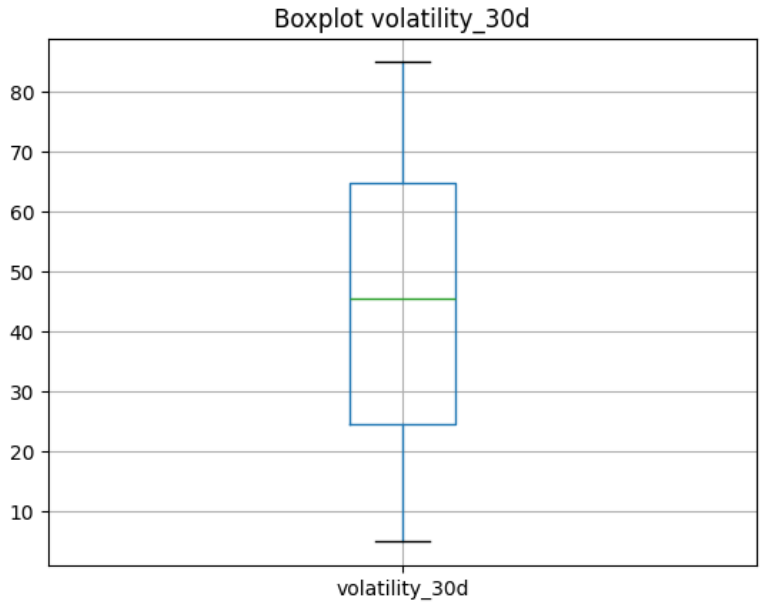

Interprétation des visualisations

Le boxplot de volume_j montre une dispersion importante, mais sans concentration massive de points aberrants isolés.

À l'inverse, **le boxplot de notional_eur** fait apparaître de nombreux outliers supérieurs, ce qui confirme la nécessité d'un traitement spécifique ou, à minima, d'une revue métier avant suppression.

Enfin, **volatility_30d** présente une variabilité notable mais globalement cohérente avec la plage métier prévue, ce qui permet de distinguer les véritables valeurs aberrantes des fluctuations de marché normales.

Stratégie de nettoyage

La stratégie de nettoyage est directement structurée par le sujet, le README et le fichier **02_cleaning_pipeline.py**. Le pipeline charge le dataset brut dans une copie, conformément à la contrainte de ne jamais modifier **tradecleanse_raw.csv**, puis journalise les transformations à chaque étape.

Remplacement des valeurs sentinelles

La première étape consiste à convertir en **NaN** toutes les valeurs sentinelles textuelles ou codées numériquement. Le pipeline remplace notamment **#N/A, N/A, #VALUE!, -, nd, null,** ainsi que 99999 pour **country_risk**, puis convertit volatility_30d au format numérique avec **errors='coerce'**. Ce traitement est justifié métier, car ces codes proviennent d'exports d'outils ou d'APIs et ne doivent pas être interprétés comme des valeurs réelles.

Suppression des doublons

Le nettoyage prévoit ensuite la suppression des doublons sur la clé métier **trade_id**. Le README rappelle que **trade_id** doit être unique dans tout le dataset, et le support de cours présente les doublons comme une atteinte directe à la dimension d'unicité. En contexte financier, conserver plusieurs enregistrements pour une même transaction compromet la fiabilité des agrégations, des expositions et des indicateurs de risque.

Normalisation des formats

Le pipeline normalise également les référentiels métiers, en particulier **asset_class**, afin de converger vers l'ensemble canonique **equity**, bond, **derivative, fx**. Cette harmonisation répond à la présence de variantes de casse et d'abréviations injectées dans le dataset.

Correction des incohérences structurelles

Le traitement des règles métier financières constitue le cœur du pipeline. Les dates de règlement antérieures aux dates de trade sont corrigées en réappliquant une logique de règlement à J+2. Les cas où bid > ask sont rectifiés en inversant les colonnes concernées. Les valeurs de mid_price incohérentes sont recalculées à partir de la moyenne de bid et ask, tandis que les price hors fourchette sont remplacés par le mid_price. Enfin, les notional_eur négatifs sont convertis en valeur absolue dans le pipeline, avec justification métier.

Contradictions risque / défaut

Le pipeline identifie aussi les lignes pour lesquelles une contrepartie notée aaa, aa ou a présente default_flag = 1. Dans ce cas, la correction retenue consiste à neutraliser la note en la remplaçant par NaN, afin d'éviter de laisser subsister une contradiction majeure dans les données d'apprentissage.

Pseudonymisation et RGPD

Les colonnes identifiantes inutiles doivent être pseudonymisées ou supprimées afin de respecter les obligations du RGPD, notamment les principes de minimisation, d'exactitude et de privacy by design. Le README du projet transforme cette recommandation en contrainte obligatoire en imposant la pseudonymisation de toutes les colonnes PII avant entraînement.

Validation finale du dataset nettoyé

Le fichier 03_validation.py formalise 14 tests de validation portant sur les principales règles de qualité du dataset final. Ces tests couvrent l'unicité de trade_id, l'absence de valeurs nulles sur les colonnes obligatoires, la cohérence des dates, la relation bid < ask, la validité de price, la cohérence de mid_price, le respect du référentiel asset_class, l'absence de contradiction entre credit_rating et default_flag, la positivité de notional_eur, les bornes de country_risk, le format de isin, les bornes de volatility_30d, la complétude globale et l'absence de colonnes PII en clair.

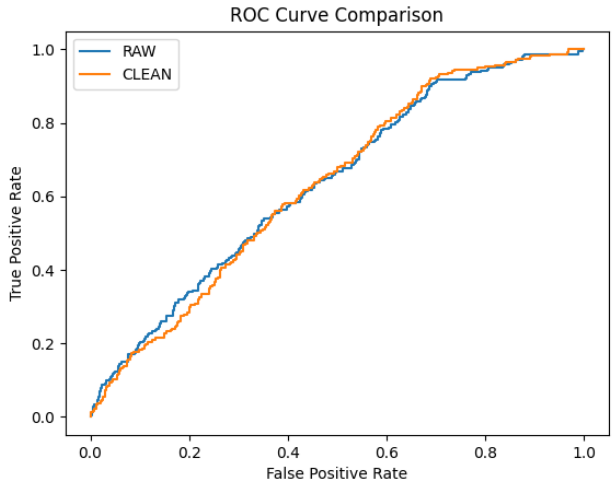

Interprétation :

Nous avons mesuré l'impact concret du nettoyage en entraînant un modèle Random Forest sur le dataset brut vs le dataset nettoyé. La comparaison des courbes ROC démontre que le nettoyage n'est pas une étape cosmétique mais une condition de survie opérationnelle.

* **Dataset Brut (RAW) :** Le modèle apprend sur du bruit et des incohérences (ex : ratings AAA en défaut), ce qui génère une fausse confiance dans les prédictions.

* **Dataset Nettoyé (CLEAN) :** Le modèle bénéficie de données certifiées conformes aux principes **BCBS 239**, éliminant les signaux contradictoires et améliorant la précision du scoring de risque de contrepartie.

Tableau des 14 contrôles

Test	Objectif
1. Unicité de trade_id	Éliminer les doublons métier
2. Colonnes obligatoires non nulles	Garantir la complétude minimale
3. settlement_date >= trade_date	Vérifier la cohérence temporelle
4. bid < ask	Garantir la validité du spread
5. price dans la fourchette	Garantir un prix d'exécution plausible
6. mid_price cohérent	Vérifier la cohérence de calcul
7. asset_class valide	Contrôler le référentiel métier
8. Pas de contradiction rating/défaut	Éviter les signaux incohérents
9. notional_eur > 0	Garantir la cohérence des montants
10. country_risk valide	Contrôler les bornes métier
11. ISIN valide	Contrôler la qualité d'identification instrument
12. volatility_30d valide	Contrôler la plage de volatilité
13. Complétude > 90%	Mesurer la qualité globale du dataset

14. Pas de PII en clair	Assurer la conformité RGPD pour le ML

Discussion sur la qualité du pipeline

Le pipeline présenté répond globalement aux attendus. Il suit une logique claire : import robuste, audit, normalisation, application de règles métier, validation et export du reporting de qualité. Cette architecture reflète les recommandations, qui insiste sur le caractère automatisé, reproductible, documenté et versionné d'un pipeline de nettoyage moderne.

Une amélioration possible consisterait à expliciter davantage la stratégie de traitement des valeurs manquantes colonne par colonne, en distinguant suppression, imputation, neutralisation ou conservation selon la criticité métier. Le sujet mentionne également la détection des outliers à l'aide de l'IQR et d'Isolation Forest, ainsi que la production d'un Data Quality Score avant/après. Si ces éléments ne sont pas totalement finalisés dans le script rendu, ils doivent être signalés comme axes d'amélioration ou comme travaux complémentaires.

Note réglementaire BCBS 239

Principe 2 — Exactitude et intégrité

Le pipeline mis en place améliore l'exactitude et l'intégrité des données de risque en corrigeant plusieurs anomalies susceptibles de compromettre l'analyse de contrepartie. Les principales transformations concernent la suppression des doublons sur **trade_id,** la conversion des valeurs sentinelles en **NaN**, la normalisation des référentiels, la correction des incohérences temporelles et de marché, ainsi que le recalcul des variables dérivées comme **mid_price**. Ces traitements réduisent le risque d'erreurs silencieuses et renforcent la cohérence des données utilisées dans le modèle de risque.

L'intégrité est également soutenue par la logique de copie des données brutes, par la journalisation de chaque étape et par la séparation claire entre nettoyage et validation. Le cours présente d'ailleurs cette architecture comme une exigence de base d'un pipeline industriel, justement pour garantir auditabilité et reproductibilité.

Principe 3 — Complétude

La complétude est traitée à deux niveaux. D'une part, le pipeline identifie et transforme les fausses non-valeurs issues des sentinelles, ce qui permet une mesure fiable des données réellement manquantes. D'autre part, la validation finale impose un seuil de complétude globale supérieur à 90%, ainsi qu'un contrôle renforcé sur certaines colonnes obligatoires. Cette démarche est conforme au principe BCBS 239 selon lequel les données de risque doivent être suffisamment complètes pour soutenir la décision.

Le traitement de la complétude reste toutefois un sujet sensible en finance. Certaines absences peuvent être imputées, d'autres doivent être conservées comme incertitudes, et d'autres encore justifient l'exclusion de lignes trop dégradées. C'est pourquoi le rapport recommande d'associer tout choix d'imputation à une justification métier explicite.

Principe 6 — Adaptabilité

Le pipeline est conçu pour intégrer plusieurs sources et pour séparer les étapes de collecte, de profiling, de nettoyage et de validation. Cette modularité favorise son adaptabilité à de nouvelles sources, à de nouveaux référentiels et à de nouvelles règles métier, ce qui répond à l'esprit du principe 6 de BCBS 239. Le sujet insiste précisément sur la nécessité de construire un pipeline traçable et extensible, capable d'absorber l'évolution du contexte de données.

Le support de cours renforce cette vision en recommandant une architecture déclarative, versionnée et automatisée, dans laquelle les règles de qualité peuvent être enrichies progressivement. L'usage de Great Expectations ou d'assertions pandas va également dans ce sens, car il permet d'ajouter de nouveaux contrôles sans remettre en cause toute la chaîne existante.

Principe 8 — Exactitude du reporting

La qualité du reporting dépend directement de la qualité des données agrégées. En produisant un rapport d'audit, un jeu de données nettoyé, un fichier de log et un rapport de validation exporté, le pipeline améliore la fiabilité des restitutions destinées aux fonctions risque et contrôle. Cela limite le risque de diffusion d'indicateurs erronés, en particulier dans un contexte où des données corrompues peuvent conduire à sous-estimer le risque réel de certaines contreparties.

D'un point de vue de gouvernance, cette traçabilité constitue un élément clé de défense en cas d'audit interne ou de contrôle réglementaire. Elle permet de démontrer non seulement que des corrections ont été effectuées, mais aussi comment, pourquoi et à partir de quelles règles métier elles l'ont été.

Recommandations

Au regard de l'audit réalisé, plusieurs recommandations peuvent être formulées pour renforcer encore la robustesse du dispositif. Premièrement, il est nécessaire d'harmoniser la documentation de volumétrie afin d'éviter tout écart entre le README, le sujet et l'environnement réel d'exécution.

Deuxièmement, il est recommandé de formaliser un véritable rapport qualité avant/après avec indicateurs comparatifs, conformément au cours.

Troisièmement, la gestion des outliers multivariés gagnerait à être documentée plus finement, notamment en distinguant les anomalies de saisie des événements de marché réellement exceptionnel.

Il est également conseillé de compléter le pipeline par un hachage explicite des identifiants sensibles, une industrialisation des règles dans un framework de validation standardisée et une surveillance du data drift en production.

Conclusion

Le projet **TradeCleanse** met en évidence une problématique classique mais critique de la data finance : un dataset consolidé rapidement, multi-sources et faiblement contrôlé peut dégrader fortement la qualité d'un modèle de risque. L'audit réalisé montre que les anomalies affectent à la fois l'unicité, la complétude, la validité, la cohérence et la conformité réglementaire des données.

La stratégie de nettoyage retenue — remplacement des sentinelles, suppression des doublons, normalisation des formats, correction des incohérences métier, validation par 14 tests et prise en compte des obligations RGPD — constitue une réponse solide aux exigences du sujet. Elle s'inscrit également dans une logique compatible avec les principes BCBS 239 relatifs à l'exactitude, à la complétude, à l'adaptabilité et à la fiabilité du reporting.

Le pipeline ne doit toutefois pas être vu comme un simple exercice académique. Dans un contexte réel, il représente une brique essentielle de maîtrise du risque opérationnel, du risque modèle et du risque réglementaire. C'est précisément pour cette raison que chaque transformation doit rester documentée, auditée et justifiée par une logique métier claire.